

RNN

2013551 雷贺奥

RNN

实验要求

原始版本RNN

网络结构

loss图

准确度图

预测矩阵图

Lstm 库

网络结构

loss图

准确度

预测矩阵图

Lstm 优于RNN的原因

自己实现的Lstm

网络结构

loss图

准确度

预测矩阵图

实验要求

- 掌握RNN原理
- 学会使用PyTorch搭建循环神经网络来训练名字识别
- 学会使用PyTorch搭建LSTM网络来训练名字识别

原始版本RNN

网络结构

```
class RNN(nn.Module):
    def __init__(self, input_size, hidden_size, output_size):
        super(RNN, self).__init__()
        self.hidden_size = hidden_size
        self.i2h = nn.Linear(input_size + hidden_size, hidden_size)
        self.i2o = nn.Linear(input_size + hidden_size, output_size)
        self.softmax = nn.LogSoftmax(dim=1)

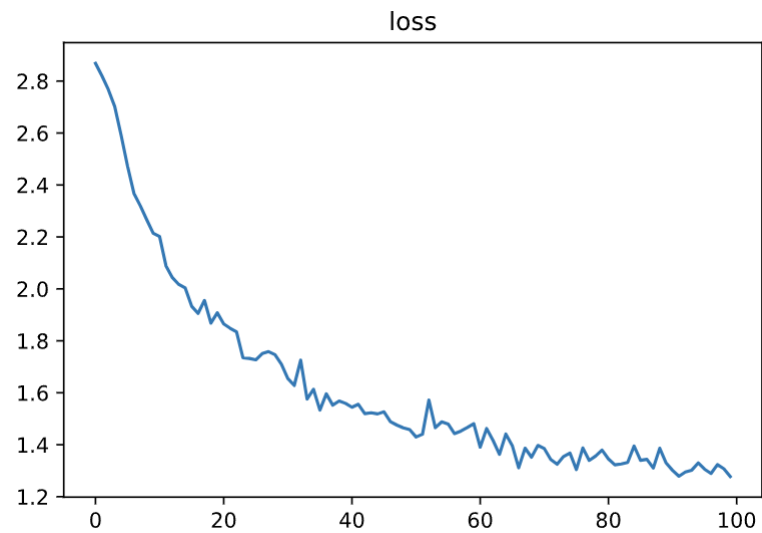
    def forward(self, input, hidden):
        combined = torch.cat((input, hidden), 1)
        hidden = self.i2h(combined)
        output = self.i2o(combined)
        output = self.softmax(output)
        return output, hidden

    def initHidden(self):
        return torch.zeros(1, self.hidden_size)
```


使用print()函数打印网络结构的结果如下：

```
RNN(  
  (i2h): Linear(in_features=185, out_features=128, bias=True)  
  (i2o): Linear(in_features=185, out_features=18, bias=True)  
  (softmax): LogSoftmax(dim=1)  
)
```


loss图



准确度图



预测矩阵图



可以看出，对角线十分清晰，预测效果良好。

Lstm 库

网络结构

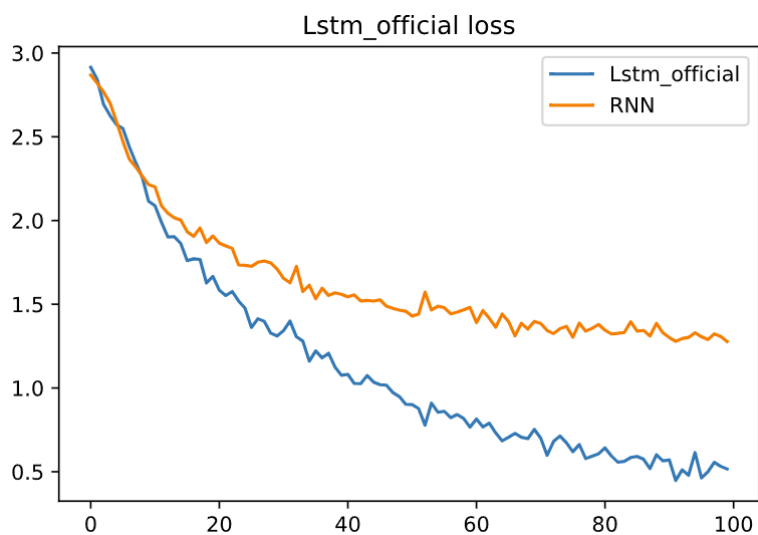
作者先使用pytorch提供的Lstm库，在最后一段展示自己手写的Lstm网络。

```
class Lstm_official(nn.Module):
    def __init__(self, input_size, hidden_size, output_size):
        super(Lstm_official, self).__init__()
        self.lstm=nn.LSTM(input_size,hidden_size,2)
        self.linear=nn.Sequential(
            nn.Linear(hidden_size,output_size),
            nn.LogSoftmax(dim=1)
        )
    def forward(self, input):
        x, (h_n, c_n)=self.lstm(input)
        # 只使用最后一次的输出
        x=self.linear(x[-1])
        return x
```


使用print()函数打印网络结构的结果如下：

```
Lstm_official(
  (lstm): LSTM(57, 128, num_layers=2)
  (linear): Sequential(
    (0): Linear(in_features=128, out_features=18, bias=True)
    (1): LogSoftmax(dim=1)
  )
)
```


loss图



准确度



预测矩阵图



Lstm 优于RNN的原因

RNN在处理的Sequence长度很长时会产生梯度爆炸或消失，所以循环神经网络（RNN）实际上只能学习到短期的依赖关系。下面证明产生梯度爆炸或消失的原因：（来源：智能计算系统课程PPT）

损失函数对 W 的偏导为：

$$\frac{\partial L}{\partial W} = \sum_{t=1}^{\tau} \frac{\partial L^{(t)}}{\partial W} = \sum_{t=1}^{\tau} \sum_{k=1}^t \frac{\partial L^{(t)}}{\partial \hat{\mathbf{y}}^{(t)}} \frac{\partial \hat{\mathbf{y}}^{(t)}}{\partial \mathbf{o}^{(t)}} \frac{\partial \mathbf{o}^{(t)}}{\partial \mathbf{h}^{(t)}} \frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} \frac{\partial \mathbf{h}^{(k)}}{\partial W}$$

因为：

$$\frac{\partial \mathbf{h}^{(t)}}{\partial \mathbf{h}^{(k)}} = \prod_{i=k+1}^t \frac{\partial \mathbf{h}^{(i)}}{\partial \mathbf{h}^{(i-1)}}$$

根据推导可知序列损失函数对 U 和 W 的偏导为：

$$\begin{aligned} \frac{\partial L}{\partial W} &= \sum_t \sum_{k=1}^{k=t} \frac{\partial L^{(t)}}{\partial \hat{\mathbf{y}}^{(t)}} \frac{\partial \hat{\mathbf{y}}^{(t)}}{\partial \mathbf{o}^{(t)}} \frac{\partial \mathbf{o}^{(t)}}{\partial \mathbf{h}^{(t)}} \left(\prod_{i=k+1}^t W^{\top} \text{diag} \left(1 - (\mathbf{h}^{(i)})^2 \right) \right) \frac{\partial \mathbf{h}^{(k)}}{\partial W} \\ \frac{\partial L}{\partial U} &= \sum_t \sum_{k=1}^{k=t} \frac{\partial L^{(t)}}{\partial \hat{\mathbf{y}}^{(t)}} \frac{\partial \hat{\mathbf{y}}^{(t)}}{\partial \mathbf{o}^{(t)}} \frac{\partial \mathbf{o}^{(t)}}{\partial \mathbf{h}^{(t)}} \left(\prod_{i=k+1}^t W^{\top} \text{diag} \left(1 - (\mathbf{h}^{(i)})^2 \right) \right) \frac{\partial \mathbf{h}^{(k)}}{\partial U} \end{aligned}$$

$$\text{令 } \gamma = \left\| \prod_{i=k+1}^t W^{\top} \text{diag} \left(1 - (\mathbf{h}^{(i)})^2 \right) \right\|_2$$

当Sequence长度很长时， $t \gg k$ ，就会产生爆炸或消失。

$$r \begin{cases} \rightarrow \infty, \frac{\partial L}{\partial U} \rightarrow \infty, \frac{\partial L}{\partial W} \rightarrow \infty \\ \rightarrow 0, \frac{\partial L}{\partial W} \rightarrow 0, \frac{\partial L}{\partial U} \rightarrow 0 \end{cases}$$

。。。。。。以后再写

自己实现的Lstm

网络结构

作者自己实现的为两层Lstm，在myLstm中嵌套两个myLstmbase。

```
class myLstmbase(nn.Module):
    def __init__(self, input_sz, hidden_sz):
        super().__init__()
        self.input_size=input_sz
        self.hidden_size=hidden_sz
        #输入参数
        self.U_i=nn.Parameter(torch.Tensor(input_sz,hidden_sz))
        self.V_i = nn.Parameter(torch.Tensor(hidden_sz,hidden_sz))
        self.b_i = nn.Parameter(torch.Tensor(hidden_sz))

        #遗忘门参数
        self.U_f = nn.Parameter(torch.Tensor(input_sz, hidden_sz))
        self.V_f = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz))
        self.b_f = nn.Parameter(torch.Tensor(hidden_sz))

        #记忆门参数
        self.U_c = nn.Parameter(torch.Tensor(input_sz, hidden_sz))
        self.V_c = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz))
```

```

self.b_c = nn.Parameter(torch.Tensor(hidden_sz))

#输出门参数
self.U_o = nn.Parameter(torch.Tensor(input_sz, hidden_sz))
self.V_o = nn.Parameter(torch.Tensor(hidden_sz, hidden_sz))
self.b_o = nn.Parameter(torch.Tensor(hidden_sz))

self.init_weights()

# 初始化, 采用正态分布
def init_weights(self):
    stdv = 1.0 / math.sqrt(self.hidden_size)
    for weight in self.parameters():
        weight.data.uniform_(-stdv, stdv)

# 前向
def forward(self,x,h_t,c_t):
    bs,seq_size = x.size()
    #计算
    x_t = x
    i_t = torch.sigmoid(x_t @ self.U_i + h_t @ self.V_i + self.b_i)
    f_t = torch.sigmoid(x_t @ self.U_f + h_t @ self.V_f + self.b_f)
    g_t = torch.tanh(x_t @ self.U_c + h_t @ self.V_c + self.b_c)
    o_t = torch.sigmoid(x_t @ self.U_o + h_t @ self.V_o + self.b_o)
    c_t = f_t * c_t + i_t * g_t
    h_t = o_t * torch.tanh(c_t)

    hidden_seq=h_t
    return hidden_seq, (h_t, c_t)


# 两层lstm
class myLstm(nn.Module):
    def __init__(self,input_sz,hidden_sz,output_size):
        super().__init__()
        self.input_size=input_sz
        self.hidden_size=hidden_sz
        # 第一层lstm
        self.lstm1 = myLstmBase(input_sz,hidden_sz)
        # 第二层lstm
        self.lstm2 = myLstmBase(input_sz,hidden_sz)
        # linear
        self.linear=nn.Sequential(
            nn.Linear(hidden_sz,output_size),
            nn.LogSoftmax(dim=1)
        )
    def forward(self,x,h_t,c_t):
        # layer1
        hidden_seq,(temp_h_t,temp_c_t) = self.lstm1(x,h_t,c_t)
        # layer2
        hidden_seq,(temp_h_t,temp_c_t) = self.lstm2(x,temp_h_t,temp_c_t)
        # result
        result = self.linear(hidden_seq)
        return result,(temp_h_t,temp_c_t)

```

使用print()打印网络结构

```
myLstm(  
  (lstm1): myLstmbase()  
  (lstm2): myLstmbase()  
  (linear): Sequential(  
    (0): Linear(in_features=128, out_features=18, bias=True)  
    (1): LogSoftmax(dim=1)  
  )  
)
```


loss图



从图中可以看出，自己实现的Lstm与调库实现的Lstm的Loss曲线趋势基本相同，最终，自己实现的Lstm甚至优于调库实现的Lstm。

但是，自己实现的Lstm训练时间很长，远大于调库实现的Lstm。

准确度



从图中可以看出，自己实现的Lstm与调库实现的Lstm的accuracy曲线趋势基本相同，最终，自己实现的Lstm甚至优于调库实现的Lstm。

